



Amazon EC2 Auto Scaling

© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

1



Principal objetivo da lição

Você aprenderá a fazer o seguinte:

- Descrever o Amazon EC2 Auto Scaling e os modelos de inicialização.
- Configurar e gerenciar modelos de inicialização e controlar o scaling.
- Identificar as práticas recomendadas para implementar o auto scaling.



Visão geral sobre o Amazon EC2 Auto Scaling

© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

3



O que é o Amazon EC2 Auto Scaling?



Amazon EC2
Auto Scaling



- O Amazon EC2 Auto Scaling é um serviço que ajuda a garantir a disponibilidade da aplicação ao iniciar ou encerrar automaticamente instâncias do EC2 com base nas opções de scaling definidas por você.
- As opções de scaling disponíveis são as seguintes:
 - Scaling manual
 - Scaling programado
 - Scaling dinâmico
 - Scaling preditivo

© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

4

Você pode usar o Amazon EC2 Auto Scaling para manter a disponibilidade da aplicação. Esse serviço ajuda a garantir que você tenha o número correto de instâncias do Amazon Elastic Compute Cloud (Amazon EC2) disponíveis para lidar com a carga da aplicação. É possível usar o Amazon EC2 Auto Scaling para adicionar ou remover automaticamente instâncias do EC2 de acordo com as condições que você definir. Por exemplo, você pode configurar o Amazon EC2 Auto Scaling para encerrar instâncias do EC2 que falham nas verificações de status de integridade. Depois, você pode configurá-lo para iniciar novas instâncias do EC2 a fim de substituir as encerradas. Você pode criar políticas definidas pelo usuário que usam o Amazon CloudWatch para iniciar os momentos de adicionar ou remover instâncias do EC2. Essas políticas seriam baseadas em condições, como a utilização média de CPU da sua frota do Amazon EC2.

A opção de scaling mais básica é o scaling manual. Você especifica a mudança na capacidade

Você pode usar o Amazon EC2 Auto Scaling para manter a disponibilidade da aplicação. Esse serviço ajuda a garantir que você tenha o número correto de instâncias do Amazon Elastic Compute Cloud (Amazon EC2) disponíveis para lidar com a carga da aplicação. É possível usar o Amazon EC2 Auto Scaling para adicionar ou remover automaticamente instâncias do EC2 de acordo com as condições que você definir. Por exemplo, você pode configurar o Amazon EC2 Auto Scaling para encerrar instâncias do EC2 que falham nas verificações de status de integridade. Depois, você pode configurá-lo para iniciar novas instâncias do EC2 a fim de substituir as encerradas. Você pode criar políticas definidas pelo usuário que usam o Amazon CloudWatch para iniciar os momentos de adicionar ou remover instâncias do EC2. Essas políticas seriam baseadas em condições, como a utilização média de CPU da sua frota do Amazon EC2.

A opção de scaling mais básica é o scaling manual. Você especifica a mudança na capacidade máxima, mínima ou desejada do seu grupo do Auto Scaling, e o Amazon EC2 Auto Scaling implementa a alteração.


Se você tem alterações de carga previsíveis a fazer, pode definir uma programação por meio do Amazon EC2 Auto Scaling para planejar as ações de scaling. Os recursos do Amazon EC2 Auto Scaling oferecem a capacidade de aumentar a escala horizontalmente para atender à demanda e reduzir a escala horizontalmente para diminuir os custos.

Você examinará as seguintes opções de scaling de maneira mais detalhada nos próximos slides:

- Programado
- Dinâmico
- Preditivo

Conceitos do Auto Scaling

- Capacidade
- Aumentar ou reduzir a escala horizontalmente
- Integridade da instância
- Política de encerramento
- Modelo de inicialização



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

5

Os principais conceitos do auto scaling incluem o seguinte:

Capacidade: os limites de capacidade representam os tamanhos mínimo e máximo desejados para o grupo do Auto Scaling. A capacidade desejada do grupo representa a capacidade inicial do grupo do Auto Scaling no momento da criação. Por exemplo, no diagrama, o grupo do Auto Scaling tem um tamanho mínimo de uma instância, uma capacidade desejada de duas instâncias e um tamanho máximo de quatro instâncias. As políticas de scaling que você define ajustam o número de instâncias dentro da faixa definida pelos valores mínimo e máximo.

Aumentar e reduzir a escala horizontalmente: um aumento na utilização da CPU fora da faixa desejada pode fazer com que o grupo do Auto Scaling sofra aumento da escala horizontal (adicionando duas instâncias ao grupo do Auto Scaling no exemplo mostrado). Depois, quando a

Os principais conceitos do auto scaling incluem o seguinte:

Capacidade: os limites de capacidade representam os tamanhos mínimo e máximo desejados para o grupo do Auto Scaling. A capacidade desejada do grupo representa a capacidade inicial do grupo do Auto Scaling no momento da criação. Por exemplo, no diagrama, o grupo do Auto Scaling tem um tamanho mínimo de uma instância, uma capacidade desejada de duas instâncias e um tamanho máximo de quatro instâncias. As políticas de scaling que você define ajustam o número de instâncias dentro da faixa definida pelos valores mínimo e máximo.

Aumentar e reduzir a escala horizontalmente: um aumento na utilização da CPU fora da faixa desejada pode fazer com que o grupo do Auto Scaling sofra aumento da escala horizontal (adicionando duas instâncias ao grupo do Auto Scaling no exemplo mostrado). Depois, quando a utilização da CPU diminui, o grupo do Auto Scaling sofre redução da escala horizontal, potencialmente encerrando instâncias para retornar à capacidade mínima desejada.

Integridade da instância: o status de integridade de uma instância de auto scaling indica se ela está íntegra ou não. Essa notificação pode ser proveniente de origens como o Amazon EC2, Elastic Load Balancing (ELB) ou de verificações de integridade personalizadas. Quando o Amazon EC2 Auto Scaling detecta uma instância não íntegra, ele encerra a instância e inicia uma nova.

Política de encerramento: o Amazon EC2 Auto Scaling usa políticas de encerramento para determinar quais instâncias serão encerradas primeiro durante eventos de redução da escala horizontal.

Modelo de inicialização: um modelo de inicialização especifica as informações de configuração da instância. Ele inclui o ID da imagem de máquina da Amazon (AMI), o tipo de instância, um par de chaves, grupos de segurança e outros parâmetros usados para iniciar instâncias do EC2. Quando os grupos do Auto Scaling sofrem aumento da escala horizontal, as novas instâncias são iniciadas de acordo com as informações de configuração especificadas na versão mais recente do modelo de

Política de Auto Scaling

O auto scaling pode ser definido de três maneiras:



Alarmes do Amazon
CloudWatch



Política com
monitoramento
de objetivo



Ações programadas



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

6

Lembre-se de que o auto scaling pode ser definido de três maneiras:

- Defina uma política de scaling que aumenta ou reduz a escala horizontalmente com base em um alarme do Amazon CloudWatch. Você pode definir um alarme do CloudWatch, como Utilização média da CPU maior que 50% por 2 minutos, que chama uma política do Amazon EC2 Auto Scaling. A política especifica uma das duas opções. A primeira opção (scaling simples) serve para adicionar ou remover um número fixo de instâncias. A segunda opção (scaling em etapas) serve para ajustar o número de instâncias em execução como uma porcentagem da capacidade desejada para o grupo do Amazon EC2 Auto Scaling. A resposta varia de acordo com o tamanho da violação do alarme.
- Defina uma política com monitoramento de objetivo em que uma métrica, como a utilização média da CPU, seja avaliada em relação a uma meta. Por exemplo, mantenha a utilização média da CPU do seu grupo do Auto Scaling em 50%.


Alarmes do Amazon CloudWatch	Política com monitoramento de objetivo	Ações programadas
		
© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.		
6		

Lembre-se de que o auto scaling pode ser definido de três maneiras:

- Defina uma política de scaling que aumenta ou reduz a escala horizontalmente com base em um alarme do Amazon CloudWatch. Você pode definir um alarme do CloudWatch, como Utilização média da CPU maior que 50% por 2 minutos, que chama uma política do Amazon EC2 Auto Scaling. A política especifica uma das duas opções. A primeira opção (scaling simples) serve para adicionar ou remover um número fixo de instâncias. A segunda opção (scaling em etapas) serve para ajustar o número de instâncias em execução como uma porcentagem da capacidade desejada para o grupo do Amazon EC2 Auto Scaling. A resposta varia de acordo com o tamanho da violação do alarme.
- Defina uma política com monitoramento de objetivo em que uma métrica, como a utilização média da CPU, seja avaliada em relação a uma meta. Por exemplo, mantenha a utilização média da CPU do seu grupo do Auto Scaling em 50%.
- Definir uma ação programada. As ações programadas definem um novo valor de capacidade desejado em um horário específico. Você pode especificar uma ação programada para que comece em uma data e hora específicas. Você também pode especificar uma ação recorrente executada em momentos específicos durante uma semana, mês ou ano. As ações programadas são uma excelente maneira de pré-aquecer a capacidade em resposta a picos de tráfego previstos.

Scaling programado

Exemplo de tráfego semanal para uma aplicação



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

7

Ao escalar com base em um cronograma, você pode ajustar a escala da aplicação em resposta a mudanças de carga previsíveis. Por exemplo, digamos que toda semana o tráfego para o aplicativo web começa a aumentar na quarta-feira, permanece parcialmente alto na quinta-feira e começa a diminuir na sexta-feira. Em situações como essa, você pode planejar as ações de scaling com base nos padrões de tráfego previsível do aplicativo web.

As etapas para configurar um grupo do Auto Scaling para que escale com base em um cronograma são as seguintes:

1. Crie uma ação programada que informe ao Amazon EC2 Auto Scaling para executar uma ação de scaling em horários especificados.
2. Especifique o horário de início em que a ação de scaling deve entrar em vigor, além dos novos tamanhos mínimo, máximo e desejado para a ação de scaling.

Ao escalar com base em um cronograma, você pode ajustar a escala da aplicação em resposta a mudanças de carga previsíveis. Por exemplo, digamos que toda semana o tráfego para o aplicativo web começa a aumentar na quarta-feira, permanece parcialmente alto na quinta-feira e começa a diminuir na sexta-feira. Em situações como essa, você pode planejar as ações de scaling com base nos padrões de tráfego previsível do aplicativo web.

As etapas para configurar um grupo do Auto Scaling para que escale com base em um cronograma são as seguintes:

1. Crie uma ação programada que informe ao Amazon EC2 Auto Scaling para executar uma ação de scaling em horários especificados.
2. Especifique o horário de início em que a ação de scaling deve entrar em vigor, além dos novos tamanhos mínimo, máximo e desejado para a ação de scaling.
3. No horário especificado, o Amazon EC2 Auto Scaling atualiza o grupo para que corresponda aos valores de capacidade especificados na ação de scaling.

Para obter mais informações, consulte “Scheduled Scaling for Amazon EC2 Auto Scaling” (Scaling programado para o Amazon EC2 Auto Scaling) em <https://docs.aws.amazon.com/autoscaling/ec2/userguide/ec2-auto-scaling-scheduled-scaling.html>.

Scaling dinâmico

O scaling dinâmico ajusta a capacidade do seu grupo do Auto Scaling à medida que ocorrem mudanças no tráfego.

Os tipos de política de scaling dinâmico incluem o seguinte:

- **Scaling com monitoramento de objetivo:** aumenta ou reduz a capacidade atual do grupo com base em um valor-alvo para uma métrica específica.
- **Scaling em etapas:** aumenta ou reduz a capacidade atual do grupo com base em um conjunto de ajustes de scaling, que é baseado no tamanho da violação do alarme.
- **Scaling simples:** aumenta ou reduz a capacidade atual do grupo com base em um único ajuste de scaling.



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

8

O auto scaling pode ser configurado para ser dinâmico. Por exemplo, digamos que você tenha um aplicativo web que é executado em duas instâncias atualmente. Você não quer que a utilização da CPU do grupo do Auto Scaling exceda 70% por mais de 2 minutos. Você pode configurar o grupo do Auto Scaling para escalar automaticamente a fim de atender a essa necessidade. O tipo de política determina como a ação de scaling será executada.

O Amazon EC2 Auto Scaling oferece suporte aos seguintes tipos de políticas de scaling:

- **Scaling com monitoramento de objetivo:** aumenta ou reduz a capacidade atual do grupo com base em um valor-alvo para uma métrica específica.
 - Esse tipo de scaling é semelhante à forma como o termostato mantém a temperatura da sua casa. Você seleciona uma temperatura e o termostato faz o resto do trabalho.
 - No caso do Amazon EC2, você define a métrica para que o Amazon EC2 Auto Scaling a



O auto scaling pode ser configurado para ser dinâmico. Por exemplo, digamos que você tenha um aplicativo web que é executado em duas instâncias atualmente. Você não quer que a utilização da CPU do grupo do Auto Scaling exceda 70% por mais de 2 minutos. Você pode configurar o grupo do Auto Scaling para escalar automaticamente a fim de atender a essa necessidade. O tipo de política determina como a ação de scaling será executada.


O Amazon EC2 Auto Scaling oferece suporte aos seguintes tipos de políticas de scaling:

- Scaling com monitoramento de objetivo: aumenta ou reduz a capacidade atual do grupo com base em um valor-alvo para uma métrica específica.
 - Esse tipo de scaling é semelhante à forma como o termostato mantém a temperatura da sua casa. Você seleciona uma temperatura e o termostato faz o resto do trabalho.
 - No caso do Amazon EC2, você define a métrica para que o Amazon EC2 Auto Scaling a monitore. O Amazon EC2 Auto Scaling faz o resto do trabalho.
- Scaling em etapas: aumenta ou reduz a capacidade atual do grupo com base em um conjunto de ajustes de scaling, que são conhecidos como ajustes em etapas. Esses ajustes de scaling variam de acordo com o tamanho da violação do alarme.
 - O Amazon EC2 Auto Scaling não oferece suporte a períodos de espera para políticas de scaling em etapas.
 - Portanto, você não pode especificar um período de espera para essas políticas, e o período de espera padrão para o grupo não se aplica.
- Scaling simples: aumenta ou reduz a capacidade atual do grupo com base em um único ajuste de scaling.
 - O scaling simples oferece suporte a um período de espera entre cada ação de scaling.

O scaling pode ser baseado em uma métrica de utilização que aumenta ou diminui proporcionalmente ao número de instâncias em um grupo do Auto Scaling. Nesse caso, a abordagem recomendada é usar políticas de scaling com monitoramento de objetivo. Caso contrário, é recomendável usar políticas de scaling em etapas.

Scaling preditivo

- Aumente a capacidade do seu grupo do Auto Scaling antes dos padrões diários e semanais nos fluxos de tráfego.
- Preveja a carga.
- Programe uma capacidade mínima.
- Use para o seguinte:
 - Aplicações com picos periódicos.
 - Definição automática dos valores de métrica desejados quando usado com uma política de scaling dinâmico com monitoramento de objetivo.



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

9

A AWS também oferece scaling preditivo. O scaling preditivo usa modelos de machine learning para prever o tráfego esperado (e o uso do Amazon EC2), incluindo padrões diários e semanais. Essas previsões usam dados coletados do uso real do Amazon EC2 e pontos de dados extraídos das suas próprias observações. O modelo precisa de dados históricos de pelo menos 1 dia para iniciar as previsões. O modelo é reavaliado a cada 24 horas para criar uma previsão para as próximas 48 horas.

O scaling preditivo elimina a necessidade de ajustar manualmente os parâmetros do auto scaling ao longo do tempo, o que torna o auto scaling menos complexo de configurar e consumir.

Para começar, acesse o Console de Gerenciamento da AWS. No canto superior direito, escolha Serviços, depois selecione Gerenciamento e governança. Nesse menu, escolha AWS Auto Scaling. Nessa página, você poderá criar um plano de scaling para os recursos do Amazon EC2 que inclui o

A AWS também oferece scaling preditivo. O scaling preditivo usa modelos de machine learning para prever o tráfego esperado (e o uso do Amazon EC2), incluindo padrões diários e semanais. Essas previsões usam dados coletados do uso real do Amazon EC2 e pontos de dados extraídos das suas próprias observações. O modelo precisa de dados históricos de pelo menos 1 dia para iniciar as previsões. O modelo é reavaliado a cada 24 horas para criar uma previsão para as próximas 48 horas.

O scaling preditivo elimina a necessidade de ajustar manualmente os parâmetros do auto scaling ao longo do tempo, o que torna o auto scaling menos complexo de configurar e consumir.

Para começar, acesse o Console de Gerenciamento da AWS. No canto superior direito, escolha Serviços, depois selecione Gerenciamento e governança. Nesse menu, escolha AWS Auto Scaling. Nessa página, você poderá criar um plano de scaling para os recursos do Amazon EC2 que inclua o scaling preditivo. Depois de ativar o scaling preditivo, você pode visualizar o tráfego previsto e as ações de scaling geradas.

Também é possível usar o scaling preditivo com o scaling dinâmico. O scaling preditivo funciona ao prever a carga e programar a capacidade mínima, enquanto o scaling dinâmico usa o monitoramento de objetivo para ajustar uma métrica designada do CloudWatch a uma meta específica. Os dois modelos funcionam bem juntos devido à capacidade mínima programada que o scaling preditivo já definiu.

O scaling preditivo é uma boa opção para sites e aplicações que enfrentam picos de tráfego periódicos. Ele não é projetado para ajudar em situações em que os picos de carga não são cíclicos ou previsíveis.

Para obter mais informações, acesse:

- Predictive Scaling Settings (Configurações de scaling preditivo) em <https://docs.aws.amazon.com/autoscaling/plans/userguide/gs-specify-custom->



Integridade da instância

Tipos de verificação de integridade:

- Verificações de status e eventos programados do Amazon EC2 (padrão)
- Verificações de integridade do Elastic Load Balancing (ELB)
- Verificações de integridade personalizadas

Exemplos de problemas que podem causar falha na verificação do status de uma instância:

- Configuração incorreta de redes ou de inicialização
- Memória esgotada
- Sistema de arquivos corrompido
- Kernel incompatível



O Amazon EC2 Auto Scaling verifica periodicamente o status de integridade de todas as instâncias dentro do grupo do Auto Scaling para garantir que elas estejam em execução e em boas condições. Se o Amazon EC2 Auto Scaling detectar que uma instância não está mais em execução, ele tratará a instância como uma falha imediata, marcará a instância como não íntegra e a substituirá.

O Amazon EC2 Auto Scaling pode determinar o status de integridade de uma instância usando uma ou mais das seguintes verificações de integridade:

- Verificações de status e eventos programados do Amazon EC2
 - Verifica se a instância está em execução.
 - Verifica se há problemas subjacentes de hardware ou software que possam prejudicar a instância.
- Verificações de integridade do ELB
 - Verifica se o balanceador de carga relata a instância como íntegra, o que confirma se a



O Amazon EC2 Auto Scaling verifica periodicamente o status de integridade de todas as instâncias dentro do grupo do Auto Scaling para garantir que elas estejam em execução e em boas condições. Se o Amazon EC2 Auto Scaling detectar que uma instância não está mais em execução, ele tratará a instância como uma falha imediata, marcará a instância como não íntegra e a substituirá.

O Amazon EC2 Auto Scaling pode determinar o status de integridade de uma instância usando uma ou mais das seguintes verificações de integridade:

- Verificações de status e eventos programados do Amazon EC2
 - Verifica se a instância está em execução.
 - Verifica se há problemas subjacentes de hardware ou software que possam prejudicar a instância.
- Verificações de integridade do ELB
 - Verifica se o balanceador de carga relata a instância como íntegra, o que confirma se a instância está disponível para lidar com solicitações.
- Verificações de integridade personalizadas
 - Verifica se há algum outro problema que possa indicar problemas de integridade da instância de acordo com suas verificações de integridade personalizadas.

Por padrão, o Amazon EC2 Auto Scaling usa verificações de status de instâncias do EC2. Se um grupo do Auto Scaling estiver por trás de um balanceador de carga, as verificações de instância do balanceador de carga ou as verificações de instância do EC2 serão usadas para monitorar a integridade, dependendo de qual delas estiver ativada.

Para obter mais informações sobre as verificações de integridade, consulte “Health Checks for Auto Scaling Instances” (Verificações de integridade para instâncias de auto scaling) em <https://docs.aws.amazon.com/autoscaling/ec2/userguide/ec2-auto-scaling-health-checks.html>.

Para obter mais informações sobre as verificações de status das instâncias, consulte “Verificações de status para as instâncias” em <https://docs.aws.amazon.com/AWSEC2/latest/UserGuide/monitoring->

Política de encerramento

Esse tipo de política determina qual instância é encerrada em uma situação de redução da escala horizontal.

Veja a seguir exemplos de uma política de encerramento:

- Padrão (Zona de Disponibilidade com o maior número de instâncias)
- Instância mais antiga
- Instância mais recente
- Modelo de inicialização mais antigo
- Mais perto da próxima hora faturável de instância



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

11

Uma política de encerramento especifica os critérios que o Amazon EC2 Auto Scaling usa para escolher uma instância para encerrar ao reduzir a escala horizontalmente. Há várias políticas de encerramento predefinidas, incluindo uma política padrão.

A política de encerramento padrão foi criada para ajudar a garantir que suas instâncias atravessassem as Zonas de Disponibilidade uniformemente para oferecer alta disponibilidade. Ao encerrar instâncias, primeiro o Amazon EC2 Auto Scaling determina quais Zonas de Disponibilidade têm mais instâncias e encontra pelo menos uma instância que não está protegida contra redução da escala horizontal. Por exemplo, o diagrama do grupo do Auto Scaling contém duas Zonas de Disponibilidade. A Zona de Disponibilidade 1 tem duas instâncias e a Zona de Disponibilidade 2 tem uma instância. Com a política de encerramento padrão, uma instância elegível da Zona de Disponibilidade 1 seria encerrada. A política de encerramento padrão costuma ser suficiente para a maioria das situações. No entanto, você tem a opção de selecionar uma diferente para melhor

Uma política de encerramento especifica os critérios que o Amazon EC2 Auto Scaling usa para escolher uma instância para encerrar ao reduzir a escala horizontalmente. Há várias políticas de encerramento predefinidas, incluindo uma política padrão.


A política de encerramento padrão foi criada para ajudar a garantir que suas instâncias atravessem as Zonas de Disponibilidade uniformemente para oferecer alta disponibilidade. Ao encerrar instâncias, primeiro o Amazon EC2 Auto Scaling determina quais Zonas de Disponibilidade têm mais instâncias e encontra pelo menos uma instância que não está protegida contra redução da escala horizontal. Por exemplo, o diagrama do grupo do Auto Scaling contém duas Zonas de Disponibilidade. A Zona de Disponibilidade 1 tem duas instâncias e a Zona de Disponibilidade 2 tem uma instância. Com a política de encerramento padrão, uma instância elegível da Zona de Disponibilidade 1 seria encerrada. A política de encerramento padrão costuma ser suficiente para a maioria das situações. No entanto, você tem a opção de selecionar uma diferente para melhor atender às suas necessidades.

O Amazon EC2 Auto Scaling fornece outras políticas de encerramento predefinidas, incluindo as seguintes:

- **OldestInstance:** essa política encerra a instância mais antiga do grupo. Essa opção é útil ao fazer upgrade das instâncias no grupo do Auto Scaling para um novo tipo de instância do EC2. Você pode gradualmente substituir instâncias do tipo antigo pelas do novo tipo.
- **NewestInstance:** essa política encerra a instância mais recente do grupo. Essa política é útil quando você está testando um novo modelo de inicialização, mas não quer mantê-lo em produção.
- **OldestLaunchTemplate:** essa política encerra instâncias que têm o modelo de inicialização mais antigo. Essa opção é boa quando você está atualizando um grupo e eliminando as instâncias de uma configuração de modelo anterior.
- **ClosestToNextInstanceHour:** essa política encerra as instâncias que estão mais perto da próxima hora de faturamento. Usar essa política é uma boa maneira de maximizar o uso de instâncias e gerenciar os custos de uso do Amazon EC2.

Ganchos de ciclo de vida

Os ganchos de ciclo de vida oferecem a oportunidade de realizar uma ação do usuário antes da conclusão de um evento de aumento ou redução da escala horizontal.



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

12

Em alguns casos, você pode querer intervir antes que uma ação do Amazon EC2 Auto Scaling adicione ou subtraia de seu grupo do Amazon EC2 Auto Scaling. Os ganchos de ciclo de vida do grupo do Amazon EC2 Auto Scaling oferecem essa flexibilidade a você.

O diagrama ilustra o seguinte:

- Durante um evento de aumento da escala horizontal, o Amazon EC2 Auto Scaling começa a iniciar uma nova instância e a coloca em estado *Pendente*. Nesse momento, você pode usar um gancho de ciclo de vida para realizar uma ação na instância. Por exemplo, você pode usar o gancho para enviar uma notificação por e-mail a um administrador de sistemas, que poderá então instalar atualizações de software de segurança na instância. Quando o administrador termina, o Amazon EC2 Auto Scaling conclui o processo de inicialização e coloca a instância no estado *Em serviço*.
- Da mesma forma, durante um evento de redução da escala horizontal, o Amazon EC2 Auto Scaling começa a encerrar uma instância e a coloca no estado *Encerrando*. Nesse momento, você



Em alguns casos, você pode querer intervir antes que uma ação do Amazon EC2 Auto Scaling adicione ou subtraia de seu grupo do Amazon EC2 Auto Scaling. Os ganchos de ciclo de vida do grupo do Amazon EC2 Auto Scaling oferecem essa flexibilidade a você.

O diagrama ilustra o seguinte:

- Durante um evento de aumento da escala horizontal, o Amazon EC2 Auto Scaling começa a iniciar uma nova instância e a coloca em estado *Pendente*. Nesse momento, você pode usar um gancho de ciclo de vida para realizar uma ação na instância. Por exemplo, você pode usar o gancho para enviar uma notificação por e-mail a um administrador de sistemas, que poderá então instalar atualizações de software de segurança na instância. Quando o administrador termina, o Amazon EC2 Auto Scaling conclui o processo de inicialização e coloca a instância no estado *Em serviço*.
- Da mesma forma, durante um evento de redução da escala horizontal, o Amazon EC2 Auto Scaling começa a encerrar uma instância e a coloca no estado *Encerrando*. Nesse momento, você pode usar um gancho de ciclo de vida para realizar uma ação na instância antes que ela seja encerrada. Por exemplo, você pode fazer com que o gancho execute um script para recuperar e fazer backup dos logs da instância para fins de auditoria. Quando o script é concluído, o Amazon EC2 Auto Scaling conclui o processo de encerramento e coloca a instância no estado *Encerrada*.

Para obter mais informações, consulte “How Lifecycle Hooks Work” (Como funcionam os ganchos de ciclo de vida) em

<https://docs.aws.amazon.com/autoscaling/ec2/userguide/lifecycle-hooks-overview.html>.



Modelos de inicialização

© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

13



O que é um modelo de inicialização?



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

14

Um modelo de inicialização especifica as informações de configuração da instância (incluindo o ID da AMI, o tipo de instância, um par de chaves, grupos de segurança e outros parâmetros) e oferece a opção de ter várias versões. O grupo do Amazon EC2 Auto Scaling mantém o número certo de instâncias do EC2 definidas pelo modelo de inicialização, dependendo de suas necessidades. Juntos, o modelo de inicialização e as políticas do grupo do Auto Scaling determinam o que iniciar dentro do grupo do Auto Scaling e como gerenciar.

Você pode criar um grupo do Auto Scaling usando uma configuração de execução, mas a AWS recomenda fortemente que você use um modelo de inicialização em vez de configurações de execução.

Criar um modelo de inicialização

Ao configurar um modelo de inicialização, você pode especificar os seguintes parâmetros:

- Imagem de máquina da Amazon (AMI)
- Tipo de instância
- Par de chaves de instância
- Grupo de segurança
- Armazenamento
- Perfis do AWS Identity and Access Management (IAM)
- Dados do usuário
- Marcação



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

15

As etapas a seguir descrevem como configurar seu modelo de inicialização:

- Especifique a AMI usada como base para iniciar as instâncias.
- Escolha um tipo de instância que seja compatível com a AMI especificada.
- Especifique o par de chaves a ser usado ao se conectar às instâncias (por exemplo, usando SSH).
- Adicione um ou mais grupos de segurança para conceder acesso à rede para as instâncias.
- Especifique se deseja anexar volumes adicionais a cada instância.
- Adicione tags personalizadas (pares de chave e valor) às instâncias e aos volumes.

Quando você cria um modelo de inicialização, todos os parâmetros são opcionais e podem ser usados para iniciar uma instância. No entanto, se você estiver criando um modelo de inicialização para um grupo do Auto Scaling, o ID da AMI e um tipo de instância serão necessários. Se uma AMI não for especificada, você não poderá adicionar a AMI ao criar o grupo do Auto Scaling.

Lembre-se de que também é possível criar versões diferentes do modelo. Por exemplo, você pode



As etapas a seguir descrevem como configurar seu modelo de inicialização:

- Especifique a AMI usada como base para iniciar as instâncias.
- Escolha um tipo de instância que seja compatível com a AMI especificada.
- Especifique o par de chaves a ser usado ao se conectar às instâncias (por exemplo, usando SSH).
- Adicione um ou mais grupos de segurança para conceder acesso à rede para as instâncias.
- Especifique se deseja anexar volumes adicionais a cada instância.
- Adicione tags personalizadas (pares de chave e valor) às instâncias e aos volumes.

Quando você cria um modelo de inicialização, todos os parâmetros são opcionais e podem ser usados para iniciar uma instância. No entanto, se você estiver criando um modelo de inicialização para um grupo do Auto Scaling, o ID da AMI e um tipo de instância serão necessários. Se uma AMI não for especificada, você não poderá adicionar a AMI ao criar o grupo do Auto Scaling.

Lembre-se de que também é possível criar versões diferentes do modelo. Por exemplo, você pode criar um modelo de inicialização que define uma configuração base sem uma AMI ou um script de dados do usuário. Depois de criar o modelo de inicialização, você pode criar outra versão e adicionar a AMI e os dados do usuário contendo a versão mais recente da aplicação para teste. Isso resulta em duas versões do modelo de inicialização.

Para conferir documentação adicional, consulte “Create a Launch Template for an Auto Scaling Group” (Criar um modelo de inicialização para um grupo do Auto Scaling) em <https://docs.aws.amazon.com/autoscaling/ec2/userguide/create-launch-template.html>.

Usar um modelo de inicialização

Especifique o modelo de inicialização e as informações necessárias para configurar as instâncias do EC2 no grupo.

- Configurações necessárias:
 - Modelo de inicialização
 - Nuvem privada virtual (VPC)
 - Sub-redes
- Configurações opcionais:
 - Registre as instâncias com um balanceador de carga.
 - Ative as verificações de integridade do ELB.
 - Ative o monitoramento com o CloudWatch.
 - Configure o tamanho do grupo.
 - Configure as políticas de scaling.



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

16

Depois de criar o modelo de inicialização, você pode usar esse modelo para configurar um grupo do Auto Scaling.

Para criar o grupo do Auto Scaling com base no modelo de inicialização, você deve fazer o seguinte:

- Escolha o modelo de inicialização e especifique as preferências de versão.
- Escolha as opções de inicialização da instância. Por exemplo, você deve criar o grupo do Auto Scaling na mesma nuvem privada virtual (VPC) do grupo de segurança especificado no modelo de inicialização.
- Escolha uma ou mais sub-redes na VPC especificada. Para oferecer alta disponibilidade, use sub-redes em várias Zonas de Disponibilidade.

Você também pode definir configurações avançadas (opcionais), como as seguintes:

- Registre as instâncias do EC2 com um balanceador de carga. Essa configuração possibilita que o tráfego seja distribuído entre várias instâncias do EC2, dependendo do workload e da integridade



Depois de criar o modelo de inicialização, você pode usar esse modelo para configurar um grupo do Auto Scaling.

Para criar o grupo do Auto Scaling com base no modelo de inicialização, você deve fazer o seguinte:

- Escolha o modelo de inicialização e especifique as preferências de versão.
- Escolha as opções de inicialização da instância. Por exemplo, você deve criar o grupo do Auto Scaling na mesma nuvem privada virtual (VPC) do grupo de segurança especificado no modelo de inicialização.
- Escolha uma ou mais sub-redes na VPC especificada. Para oferecer alta disponibilidade, use sub-redes em várias Zonas de Disponibilidade.

Você também pode definir configurações avançadas (opcionais), como as seguintes:

- Registre as instâncias do EC2 com um balanceador de carga. Essa configuração possibilita que o tráfego seja distribuído entre várias instâncias do EC2, dependendo do workload e da integridade delas.
- Ative as verificações de integridade do ELB. Essas verificações ajudam a garantir que o tráfego distribuído seja enviado somente para instâncias íntegras.
- Ative o monitoramento com a coleta de métricas do grupo do CloudWatch. O monitoramento aumenta sua visibilidade das métricas que podem ser indicadores de um possível problema, como o número de instâncias encerradas ou o número de instâncias pendentes.
- Configure políticas de tamanho do grupo. Essa configuração determina as capacidades mínima e máxima do grupo. À medida que a demanda cresce, o grupo sofre aumento da escala horizontal para usar mais instâncias. Se a demanda diminuir, o grupo reduzirá a escala horizontalmente e encerrará instâncias que não são mais necessárias.
- Configure as políticas de scaling. Essa configuração inclui a seleção de políticas de scaling com monitoramento de objetivo a fim de escalar automaticamente o tamanho do grupo do Auto Scaling. Ela também determina o status de integridade das instâncias fornecidas pelas verificações de integridade de instância do EC2, de balanceador de carga ou personalizadas. Se uma instância não estiver íntegra, ela será substituída.



Práticas recomendadas

© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

17



Configurações das métricas e do tipo de instância




CloudWatch

Use uma frequência de 1 minuto para a coleta dos dados de métricas do CloudWatch.



Amazon EC2 Auto Scaling

Ative as métricas do grupo do Auto Scaling.



Instâncias do Amazon EC2

Evite tipos de instância de desempenho expansível.



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

18

Use uma frequência de 1 minuto para a coleta dos dados de métricas do CloudWatch. Ao criar um modelo de inicialização ou uma configuração de execução, ative o monitoramento detalhado a fim de obter os dados de métricas do CloudWatch para instâncias do EC2 a cada 1 minuto para ajudar a garantir uma resposta mais rápida às mudanças de carga. O scaling em métricas com frequência de 5 minutos pode resultar em um tempo de resposta mais lento e em scaling de dados de métricas obsoletos.

Para obter mais informações, consulte “Configure Monitoring for Auto Scaling Instances” (Configurar o monitoramento para auto scaling) no *Guia do usuário do Amazon EC2 Auto Scaling* em <https://docs.aws.amazon.com/autoscaling/ec2/userguide/enable-as-instance-metrics.html>.

Ative as métricas do grupo do Auto Scaling. Caso contrário, os dados da capacidade real não serão mostrados nos gráficos de previsão de capacidade que são disponibilizados após a conclusão do



Use uma frequência de 1 minuto para a coleta dos dados de métricas do CloudWatch. Ao criar um modelo de inicialização ou uma configuração de execução, ative o monitoramento detalhado a fim de obter os dados de métricas do CloudWatch para instâncias do EC2 a cada 1 minuto para ajudar a garantir uma resposta mais rápida às mudanças de carga. O scaling em métricas com frequência de 5 minutos pode resultar em um tempo de resposta mais lento e em scaling de dados de métricas obsoletos.

Para obter mais informações, consulte “Configure Monitoring for Auto Scaling Instances” (Configurar o monitoramento para auto scaling) no *Guia do usuário do Amazon EC2 Auto Scaling* em <https://docs.aws.amazon.com/autoscaling/ec2/userguide/enable-as-instance-metrics.html>.

Ative as métricas do grupo do Auto Scaling. Caso contrário, os dados da capacidade real não serão mostrados nos gráficos de previsão de capacidade que são disponibilizados após a conclusão do assistente de criação de planos de scaling.

Para obter mais informações, consulte “Monitor CloudWatch Metrics for Your Auto Scaling Groups and Instances” (Monitorar as métricas do CloudWatch para instâncias e grupos do Auto Scaling) em <https://docs.aws.amazon.com/autoscaling/ec2/userguide/ec2-auto-scaling-cloudwatch-monitoring.html>.

Evite tipos de instância de desempenho expansível. Tenha cuidado ao usar um tipo de instância de desempenho expansível. As instâncias do EC2 com desempenho expansível, como as instâncias T3 e T2, são projetadas para fornecer um nível básico de desempenho da CPU com a capacidade de atingir um nível mais alto quando exigido pelo workload. Dependendo da meta de utilização especificada pelo plano de scaling, você pode correr o risco de ultrapassar a linha de base e ficar sem créditos de CPU, o que limita o desempenho.

Para obter mais informações, acesse:

- Principais conceitos e definições para instâncias de desempenho expansível em




Criar um grupo de estado estacionário

Grupo de estado estacionário:

- Defina um grupo do Amazon EC2 Auto Scaling com os mesmos valores **mínimo**, **máximo** e **desejado**.
- Uma instância será automaticamente recriada caso torne-se não íntegra ou se a Zona de Disponibilidade falhar.
- Ainda há possibilidade de tempo de inatividade enquanto uma instância é reciclada.

Caso de uso:

Manter um servidor NAT de estado estacionário em cada Zona de Disponibilidade.



Com as verificações de integridade do Amazon EC2 Auto Scaling, você pode criar um grupo de estado estacionário para ajudar a garantir que uma única instância esteja sempre em execução. Por exemplo, suponha que você tenha um servidor NAT o qual não quer que seja um único ponto de falha em uma arquitetura de sub-rede público-privada padrão.

Um grupo de estado estacionário é útil para essa instância.

As etapas para criar um grupo de estado estacionário para uma instância são as seguintes:

1. Crie um modelo de inicialização que crie a instância.
2. Crie um grupo do Amazon EC2 Auto Scaling com um tamanho mínimo, máximo e desejado de 1. Uma dessas instâncias pode ser marcada como não íntegra devido a uma falha na verificação da instância. Ou um script externo pode marcar a instância como não íntegra com uma chamada para o comando `aws autoscaling set-instance-health` da AWS CLI.
3. O grupo do Amazon EC2 Auto Scaling encerrará a instância existente e criará outra instância com

Com as verificações de integridade do Amazon EC2 Auto Scaling, você pode criar um grupo de estado estacionário para ajudar a garantir que uma única instância esteja sempre em execução. Por exemplo, suponha que você tenha um servidor NAT o qual não quer que seja um único ponto de falha em uma arquitetura de sub-rede público-privada padrão.

Um grupo de estado estacionário é útil para essa instância.

As etapas para criar um grupo de estado estacionário para uma instância são as seguintes:

1. Crie um modelo de inicialização que crie a instância.
2. Crie um grupo do Amazon EC2 Auto Scaling com um tamanho mínimo, máximo e desejado de 1. Uma dessas instâncias pode ser marcada como não íntegra devido a uma falha na verificação da instância. Ou um script externo pode marcar a instância como não íntegra com uma chamada para o comando `aws autoscaling set-instance-health` da AWS CLI.
3. O grupo do Amazon EC2 Auto Scaling encerrará a instância existente e criará outra instância com base no modelo de inicialização do grupo.

Observe que, em casos como a implantação de uma instância NAT, o NAT ainda é um único ponto de falha. Você ainda pode experimentar um tempo de inatividade significativo enquanto uma instância NAT com falha está sendo reciclada.

Evitar sobrecarga



Período de sustentação do alarme:

Configure alarmes para situações em que mudanças de estado são mantidas por um período especificado.



Período de espera:

- Ao aumentar ou reduzir a escala horizontalmente, suspenda outras ações de scaling por um período de espera.
- O período de espera é usado em políticas de scaling simples.



Período de aquecimento da instância:

- Especifique o número de segundos necessários para o aquecimento de uma instância recém-iniciada.
- O período de aquecimento da instância é usado para políticas de scaling em etapas.



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

20

Sobrecarga é uma condição em que há uso excessivo da memória virtual de um computador e o computador não é mais capaz de atender às necessidades de recursos das aplicações executadas nele. Ao configurar o auto scaling, evite a sobrecarga. Poderia ocorrer sobrecarga se as instâncias fossem removidas e adicionadas ou adicionadas e removidas muito rápido em sequência.

Uma forma de evitar interferências é iniciar ações de alarme somente para alterações de estado mantidas. Configure inicializações para alterações de estado mantidas por um período razoável. Por exemplo, a utilização da CPU permanece em 90% por 10 minutos.

O período de espera do Amazon EC2 Auto Scaling é outra configuração que pode ser definida para ajudar a garantir que o Amazon EC2 Auto Scaling não inicie nem encerre instâncias adicionais antes que a ação de scaling anterior entre em vigor. Por exemplo, suspenda o scaling por 5 minutos.

Sobrecarga é uma condição em que há uso excessivo da memória virtual de um computador e o computador não é mais capaz de atender às necessidades de recursos das aplicações executadas nele. Ao configurar o auto scaling, evite a sobrecarga. Poderia ocorrer sobrecarga se as instâncias fossem removidas e adicionadas ou adicionadas e removidas muito rápido em sequência.

Uma forma de evitar interferências é iniciar ações de alarme somente para alterações de estado mantidas. Configure inicializações para alterações de estado mantidas por um período razoável. Por exemplo, a utilização da CPU permanece em 90% por 10 minutos.

O período de espera do Amazon EC2 Auto Scaling é outra configuração que pode ser definida para ajudar a garantir que o Amazon EC2 Auto Scaling não inicie nem encerre instâncias adicionais antes que a ação de scaling anterior entre em vigor. Por exemplo, suspenda o scaling por 5 minutos.

Quando você escala manualmente o grupo do Amazon EC2 Auto Scaling, o padrão é não aguardar o período de espera. No entanto, você pode substituir o padrão e cumprir o período de espera. Observe que, se uma instância se tornar não íntegra, o Amazon EC2 Auto Scaling não aguardará o término do período de espera para substituir a instância não íntegra. O Amazon EC2 Auto Scaling comporta períodos de espera padrão e períodos de espera específicos ao scaling. Ele oferece suporte a períodos de espera quando são usadas políticas simples de scaling, mas não quando são utilizadas políticas com monitoramento de objetivo, políticas de scaling em etapas ou scaling programado.

Além disso, com as políticas de scaling em etapas, você pode especificar o número de segundos necessários para o aquecimento de uma instância recém-iniciada. Por exemplo, o aquecimento leva 5 minutos. Enquanto o tempo de aquecimento especificado não expirar, a instância não será contabilizada nas métricas agregadas do grupo do Auto Scaling. Ao aumentar a quantidade, a AWS também não considera como parte da capacidade atual do grupo as instâncias que estão em aquecimento. Portanto, várias violações de alarme que ficam no intervalo do mesmo ajuste em etapas resultam em uma só ação de scaling. Essa etapa ajuda a garantir que o Amazon EC2 Auto

Perguntas de verificação

1. Os engenheiros criaram uma configuração para os servidores em um grupo do Auto Scaling. Eles querem ajudar a garantir que, se a configuração do novo servidor falhar, possam removê-la rapidamente do grupo do Auto Scaling.

Qual política de encerramento alcançaria melhor os resultados desejados: OldestInstance, NewestInstance, OldestLaunchTemplate ou ClosestToNextInstanceHour?

2. Continuando com a primeira pergunta, como os engenheiros forçariam a criação de outro servidor no grupo do Auto Scaling?

Depois, se necessário, como eles forçariam a remoção do servidor com a configuração atualizada?

3. Ainda no mesmo cenário, os engenheiros descobriram que todos os servidores recém-criados no grupo do Auto Scaling estão falhando.

O que os engenheiros deveriam ter feito?

4. Quais são as três maneiras de evitar sobrecarga durante um evento de aumento ou redução da escala horizontal?



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

21

As respostas das perguntas são estas:

1. Os engenheiros criaram uma configuração para os servidores em um grupo do Auto Scaling. Eles querem ajudar a garantir que, se a configuração do novo servidor falhar, possam removê-la rapidamente do grupo do Auto Scaling.

Qual política de encerramento alcançaria melhor os resultados desejados: OldestInstance, NewestInstance, OldestLaunchTemplate ou ClosestToNextInstanceHour?

Os engenheiros devem usar a política NewestInstance. Todos os servidores do EC2 recém-lançados teriam a configuração mais recente. Como esses servidores também seriam as instâncias mais recentes, eles seriam os primeiros removidos durante um evento de dimensionamento.

2. Continuando com a primeira pergunta, como os engenheiros forçariam a criação de outro servidor no grupo do Auto Scaling?

Depois, se necessário, como eles forçariam a remoção do servidor com a configuração atualizada?

Os engenheiros podem forçar a criação de servidores ajustando o atributo de configuração do número mínimo de instâncias no grupo do Auto Scaling. Quando o valor é aumentado, o grupo do Auto Scaling inicia novas instâncias. Forçar a remoção de instâncias do EC2 exige o ajuste do valor mínimo para um valor menor. Como os engenheiros configuraram a política de encerramento como a NewestInstance, a última instância do EC2 que tiver sido iniciada será encerrada e removida do grupo.



As respostas das perguntas são estas:

1. Os engenheiros criaram uma configuração para os servidores em um grupo do Auto Scaling. Eles querem ajudar a garantir que, se a configuração do novo servidor falhar, possam removê-la rapidamente do grupo do Auto Scaling.

Qual política de encerramento alcançaria melhor os resultados desejados: OldestInstance, NewestInstance, OldestLaunchTemplate ou ClosestToNextInstanceHour?

Os engenheiros devem usar a política NewestInstance. Todos os servidores do EC2 recém-lançados teriam a configuração mais recente. Como esses servidores também seriam as instâncias mais recentes, eles seriam os primeiros removidos durante um evento de dimensionamento.

2. Continuando com a primeira pergunta, como os engenheiros forçariam a criação de outro servidor no grupo do Auto Scaling?

Depois, se necessário, como eles forçariam a remoção do servidor com a configuração atualizada?

Os engenheiros podem forçar a criação de servidores ajustando o atributo de configuração do número mínimo de instâncias no grupo do Auto Scaling. Quando o valor é aumentado, o grupo do Auto Scaling inicia novas instâncias. Forçar a remoção de instâncias do EC2 exige o ajuste do valor mínimo para um valor menor. Como os engenheiros configuraram a política de encerramento como a NewestInstance, a última instância do EC2 que tiver sido iniciada será encerrada e removida do grupo.

3. Ainda no mesmo cenário, os engenheiros descobriram que todos os servidores recém-criados no grupo do Auto Scaling estão falhando.

O que os engenheiros deveriam ter feito?

Os engenheiros devem ter atualizado o modelo de lançamento com o valor ou valores anteriores. Nesse caso, a configuração ainda está usando a nova AMI que falhou. Os engenheiros precisavam atualizar o modelo de inicialização com a AMI mais antiga.

4. Quais são as três maneiras de evitar sobrecarga durante um evento de aumento ou redução da escala horizontal?

Veja a seguir três maneiras de evitar sobrecarga:

- Configure um período de sustentação do alarme. Essa opção exige que o estado do alarme exista por um período especificado antes que um evento ocorra. No caso de um pico transitório de apenas alguns minutos, a regra não permitiria a ocorrência do scaling.
- Um período de espera ajuda a garantir que outra regra não entre em vigor por algum tempo. Essa opção ajuda a garantir a alocação de tempo para que os servidores recém-instanciados assumam a carga adicional antes da ocorrência de outro evento de scaling. Isso também é aplicável durante um evento de redução de quantidade.
- Um período de aquecimento oferece tempo para que uma nova instância do EC2 seja totalmente iniciada. Essa opção possibilita que a instância tenha tempo para iniciar e assumir o workload antes que a demanda seja reavaliada para outros eventos de redução ou aumento da escala horizontal.

Ideias principais



- O Amazon EC2 Auto Scaling ajuda a manter a disponibilidade da aplicação adicionando ou removendo automaticamente instâncias do EC2 de acordo com as condições definidas.
- O Amazon EC2 Auto Scaling consiste em três partes:
 - Modelo de inicialização
 - Grupo do Auto Scaling
 - Políticas de scaling
- O scaling pode ser baseado na integridade da instância, em alarmes do Amazon CloudWatch e no cronograma ou uso anterior (previsão).
- Sobrecarga é uma condição em que ocorre scaling e as instâncias são criadas ou removidas muito rapidamente. Para evitar sobrecarga, use os períodos de sustentação, recarga e aquecimento para os alarmes.



Agradecemos sua atenção

Correções, feedback ou outras dúvidas?
Entre em contato conosco em
<https://support.aws.amazon.com/#/contacts/aws-training>.
Todas as marcas comerciais pertencem aos respectivos proprietários.

© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

23

