



Desafio de previsão de auto scaling

© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

1





Principal objetivo da lição

Você aprenderá a prever o número de instâncias necessárias com base em políticas e alarmes.

Cenário do desafio

Você criou um grupo do Auto Scaling com a seguinte configuração básica:

- Capacidade máxima: 20
- Capacidade desejada: 10
- Capacidade mínima: 5



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

3

Você tem um grupo do Auto Scaling com capacidade máxima de 20, capacidade desejada de 10 e capacidade mínima de 5. Você decidiu criar uma política do Amazon EC2 Auto Scaling para scaling em etapas com ações de aumento e redução da escala horizontal com base na utilização média da CPU. No entanto, você não tem certeza de como a quantidade de instâncias do Amazon Elastic Compute Cloud (Amazon EC2) será aumentada ou reduzida com base nas políticas atuais definidas para controlar os comportamentos.

Para testar os comportamentos da instância, você quer conseguir prever essa quantidade de instâncias a qualquer momento, com base nas políticas e nos respectivos alarmes. Como o número de instâncias no grupo do Auto Scaling variará quando ocorrerem as condições apresentadas nos próximos slides?



Desafio de previsão de auto scaling

Atividade

Para cada condição apresentada nos slides subsequentes, faça o seguinte:

- Analise o efeito da condição no grupo do Auto Scaling.
- Preveja o número de instâncias adicionadas ou removidas.

© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

4

Registre sua previsão para cada condição, identificando a alteração resultante no número de instâncias do grupo do Auto Scaling. Veja a seguir estão alguns exemplos de previsões:

- A condição 1 não resulta em nenhuma alteração.
- A condição 2 resulta na adição de duas instâncias.



Condição 1

Alarmes da política de scaling em etapas:

- **Redução da escala horizontal:** remover uma instância quando $40\% > \text{média da CPU} > 20\%$ por mais de 2 minutos.
- **Redução da escala horizontal:** remover duas instâncias quando $20\% > \text{média da CPU} > 0\%$ por mais de 2 minutos.
- **Aumento da escala horizontal:** adicionar uma instância quando $60\% < \text{média da CPU} < 80\%$ por mais de 2 minutos.
- **Aumento da escala horizontal:** adicionar duas instâncias quando $80\% < \text{média da CPU} < 100\%$ por mais de 2 minutos.



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

5

Condição 1:

- O período de aquecimento da instância é 5 minutos.
- A utilização média da CPU foi de 63% a 70% por mais de 2 minutos.

O lado esquerdo do slide mostra os alarmes da política que você definiu para controlar o comportamento de redução e aumento da escala horizontal que deseja implementar.

Os alarmes do Amazon CloudWatch são configurados para que, quando a carga média da CPU no grupo do Auto Scaling se mantiver entre 20% e 40% por mais de 2 minutos, o tamanho do grupo seja reduzido em uma instância.

Se a carga média da CPU se mantiver inferior a 20% por mais de 2 minutos, o grupo será reduzido em duas instâncias.

Entretanto, se a utilização da CPU se mantiver entre 60% e 80% por mais de 2 minutos, será adicionada uma instância. Se exceder 80% por mais de 2 minutos, duas instâncias serão adicionadas.



O lado esquerdo do slide mostra os alarmes da política que você definiu para controlar o comportamento de redução e aumento da escala horizontal que deseja implementar.

Os alarmes do Amazon CloudWatch são configurados para que, quando a carga média da CPU no grupo do Auto Scaling se mantiver entre 20% e 40% por mais de 2 minutos, o tamanho do grupo seja reduzido em uma instância.

Se a carga média da CPU se mantiver inferior a 20% por mais de 2 minutos, o grupo será reduzido em duas instâncias.

Entretanto, se a utilização da CPU se mantiver entre 60% e 80% por mais de 2 minutos, será adicionada uma instância. Se exceder 80% por mais de 2 minutos, duas instâncias serão adicionadas.

Considere agora o que ocorrerá nas seguintes circunstâncias:

- Condição 1: a utilização média da CPU tem se mantido entre 63% e 70% por mais de 2 minutos. O período de aquecimento da instância foi definido como 5 minutos.

Preveja o número de instâncias adicionadas ou removidas.

Resultado do auto scaling: a política adiciona uma instância ao grupo do Auto Scaling, mas a nova instância não será incluída na contagem de instâncias até que seu período de aquecimento (isto é, 5 minutos) termine.

Condição 2

Alarmes da política de scaling em etapas:

- **Redução da escala horizontal:** remover uma instância quando $40\% > \text{média da CPU} > 20\%$ por mais de 2 minutos.
- **Redução da escala horizontal:** remover duas instâncias quando $20\% > \text{média da CPU} > 0\%$ por mais de 2 minutos.
- **Aumento da escala horizontal:** adicionar uma instância quando $60\% < \text{média da CPU} < 80\%$ por mais de 2 minutos.
- **Aumento da escala horizontal:** adicionar duas instâncias quando $80\% < \text{média da CPU} < 100\%$ por mais de 2 minutos.



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

6

Condição 2:

- O período de aquecimento da instância é 5 minutos.
- A pressão da CPU continua aumentando e está se mantendo entre 60% e 80%. A condição 1 ocorreu há 2 minutos.

Condição 2: a pressão da CPU continua aumentando e está se mantendo entre 60% e 80%. A condição 1 ocorreu há dois minutos.

Preveja o número de instâncias adicionadas ou removidas. Suponha que o período de aquecimento da instância esteja definido como 5 minutos.

Resultado do auto scaling: um alarme invoca a adição de mais uma instância. No entanto, essa nova instância não é adicionada porque o período de aquecimento da instância ainda não terminou.

Condição 3

Alarmes da política de scaling em etapas:

- **Redução da escala horizontal:** remover uma instância quando $40\% > \text{média da CPU} > 20\%$ por mais de 2 minutos.
- **Redução da escala horizontal:** remover duas instâncias quando $20\% > \text{média da CPU} > 0\%$ por mais de 2 minutos.
- **Aumento da escala horizontal:** adicionar uma instância quando $60\% < \text{média da CPU} < 80\%$ por mais de 2 minutos.
- **Aumento da escala horizontal:** adicionar duas instâncias quando $80\% < \text{média da CPU} < 100\%$ por mais de 2 minutos.



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

7

Condição 3:

- O período de aquecimento da instância é 5 minutos.
- Embora tenham se passado menos de 5 minutos desde que a condição 1 ocorreu, a utilização da CPU já está em 85%.

Condição 3: a condição 1 ocorreu há menos de 5 minutos, mas a utilização da CPU já está em 85%.

Preveja o número de instâncias adicionadas ou removidas. Suponha que o período de aquecimento da instância esteja definido como 5 minutos.

Resultado do auto scaling: um alarme invoca a política de auto scaling para adicionar duas instâncias. Como uma instância já está em aquecimento, apenas uma instância adicional é iniciada.

Condição 4

Alarques da política de scaling em 4 passos:

- **Redução da escala horizontal:** remover uma instância quando $40\% > \text{média da CPU} > 20\%$ por mais de 2 minutos.
- **Redução da escala horizontal:** remover duas instâncias quando $20\% > \text{média da CPU} > 0\%$ por mais de 2 minutos.
- **Aumento da escala horizontal:** adicionar uma instância quando $60\% < \text{média da CPU} < 80\%$ por mais de 2 minutos.
- **Aumento da escala horizontal:** adicionar duas instâncias quando $80\% < \text{média da CPU} < 100\%$ por mais de 2 minutos.



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

8

Condição 4:

Passou mais tempo. A primeira das duas instâncias adicionadas está aquecida e processando parte da carga. A segunda instância segue em um estado de aquecimento. No entanto, a utilização da CPU caiu para cerca de 53% nos últimos 3 minutos.

Considere agora o que ocorrerá nas seguintes circunstâncias:

Condição 4: mais tempo se passou e a primeira das duas instâncias adicionadas já está totalmente aquecida e processando parte da carga, enquanto a segunda ainda está em um estado de aquecimento. A pressão de utilização da CPU está diminuindo. A utilização média caiu para menos de 60%, mas ainda está acima de 40%.

Preveja o número de instâncias adicionadas ou removidas.

Resultado do auto scaling: nenhum alarme é invocado e nenhuma ação é tomada.



Condição 5

Alarmes da política de scaling em etapas:

- **Redução da escala horizontal:** remover uma instância quando $40\% > \text{média da CPU} > 20\%$ por mais de 2 minutos.
- **Redução da escala horizontal:** remover duas instâncias quando $20\% > \text{média da CPU} > 0\%$ por mais de 2 minutos.
- **Aumento da escala horizontal:** adicionar uma instância quando $60\% < \text{média da CPU} < 80\%$ por mais de 2 minutos.
- **Aumento da escala horizontal:** adicionar duas instâncias quando $80\% < \text{média da CPU} < 100\%$ por mais de 2 minutos.



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

9

Condição 5:

Agora, com a demanda reduzida na implantação da aplicação, a utilização da CPU diminuiu para um valor fixo de 32%.

Condição 5: agora, com 12 instâncias no grupo e talvez uma demanda reduzida na implantação da aplicação à qual esse grupo oferece suporte, a utilização da CPU ficou abaixo do limite de 40%, mantendo-se em 32%.

Preveja o número de instâncias adicionadas ou removidas.

Resultado do auto scaling: após 2 minutos abaixo do limite de 40%, um dos alarmes de redução da escala horizontal é invocado, o que inicia a política para remover uma instância.

Condição 6

Alarmes da política de scaling em etapas:

- **Redução da escala horizontal:** remover uma instância quando $40\% > \text{média da CPU} > 20\%$ por mais de 2 minutos.
- **Redução da escala horizontal:** remover duas instâncias quando $20\% > \text{média da CPU} > 0\%$ por mais de 2 minutos.
- **Aumento da escala horizontal:** adicionar uma instância quando $60\% < \text{média da CPU} < 80\%$ por mais de 2 minutos.
- **Aumento da escala horizontal:** adicionar duas instâncias quando $80\% < \text{média da CPU} < 100\%$ por mais de 2 minutos.



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

10

Condição 6:

A utilização da CPU diminuiu ainda mais e agora está em cerca de 17%.

Condição 6: a utilização da CPU diminuiu ainda mais e já está em cerca de 17%.

Preveja o número de instâncias adicionadas ou removidas.

Resultado do auto scaling: duas instâncias são removidas. Agora, o grupo tem apenas nove instâncias.

Resumo

Alarmes da política de scaling em etapas:

- **Redução da escala horizontal:** remover uma instância quando $40\% > \text{média da CPU} > 20\%$ por mais de 2 minutos.
- **Redução da escala horizontal:** remover duas instâncias quando $20\% > \text{média da CPU} > 0\%$ por mais de 2 minutos.
- **Aumento da escala horizontal:** adicionar uma instância quando $60\% < \text{média da CPU} < 80\%$ por mais de 2 minutos.
- **Aumento da escala horizontal:** adicionar duas instâncias quando $80\% < \text{média da CPU} < 100\%$ por mais de 2 minutos.



© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

11

Aqui está o gabarito do cenário de auto scaling.

1. Houve uma condição por pelo menos 2 minutos. Essa condição invocou o alarme e o alarme iniciou a política que adiciona uma instância ao grupo do Auto Scaling.
2. A pressão da CPU continua aumentando, mas ainda não ultrapassou o limite de 80% que invocaria a ação para adicionar duas instâncias. No entanto, 2 minutos depois de o alarme inicial ter sido invocado, outro alarme é invocado para adicionar uma instância, pois a utilização da CPU permanece entre 60% e 80%. Como o período de aquecimento da instância não havia terminado quando o segundo alarme foi invocado, o segundo alarme não resultou na adição de outra instância.

Aqui está o gabarito do cenário de auto scaling.

1. Houve uma condição por pelo menos 2 minutos. Essa condição invocou o alarme e o alarme iniciou a política que adiciona uma instância ao grupo do Auto Scaling.
2. A pressão da CPU continua aumentando, mas ainda não ultrapassou o limite de 80% que invocaria a ação para adicionar duas instâncias. No entanto, 2 minutos depois de o alarme inicial ter sido invocado, outro alarme é invocado para adicionar uma instância, pois a utilização da CPU permanece entre 60% e 80%. Como o período de aquecimento da instância não havia terminado quando o segundo alarme foi invocado, o segundo alarme não resultou na adição de outra instância.
3. A utilização da CPU ultrapassa o limite de 80%, o que invoca o alarme para a política de aumento da escala horizontal adicionar duas instâncias. O terceiro alarme (o primeiro alarme de 80%) ocorreu durante o período de aquecimento para a instância que foi adicionada quando o primeiro alarme foi invocado. Como uma instância já está em aquecimento, apenas uma instância adicional é iniciada.
4. Mais tempo se passou e a primeira das duas instâncias adicionadas já está totalmente aquecida e processando parte da carga, enquanto a segunda ainda está em um estado de aquecimento. A pressão de utilização da CPU está diminuindo. A utilização média caiu para menos de 60%, mas ainda está acima de 40%. No momento, não há nenhum alarme invocado.
5. Agora, com 12 instâncias no grupo e talvez uma demanda reduzida na implantação da aplicação à qual esse grupo oferece suporte, a utilização da CPU ficou abaixo do limite de 40%. Após 2 minutos abaixo do limite de 40%, um dos alarmes de redução da escala horizontal é invocado, o que inicia a política para remover uma instância.
6. A utilização da CPU diminui ainda mais, o que invoca o alarme que removerá duas instâncias, já



Agradecemos sua atenção

Correções, feedback ou outras dúvidas?
Entre em contato conosco em
<https://support.aws.amazon.com/#/contacts/aws-training>.
Todas as marcas comerciais pertencem aos respectivos proprietários.

© 2024 Amazon Web Services, Inc. ou suas afiliadas. Todos os direitos reservados.

12

